

Analýza strát ruskej techniky na Ukrajine

Šimon Fabuš

August 8, 2024

V tejto štatistickej práci chcem skúmať straty ruskej techniky a munície na Ukrajine od začiatku Ruskej invázie 24.2.2022. Zaujímam sa najmä o závislosť medzi dňom v týždni a veľkosťou strát techniky. Z načrtnutých dát sa dajú ďalej pozorovať určité štatistické zaujímavosti.

Skúmané dáta pochádzajú z datasetu: https://www.kaggle.com/datasets/piterfm/2022-ukraine-russian-war?select=russia_losses_equipment.csv. Ktoré sú aktualizované každý týždeň. V datasete sa nachádzajú aj záznamy o počte zranených, počtu obetí alebo POW nás budú zaujímať len straty techniky a munície.

Čistenie dát

Pretože som chcel skúmať hlavne straty techniky vynechal som záznamy o strate munície a zameral sa na helikoptéry, tanky, drony, lode atď. aj keď v strate munície je vidno podobný trend. Pretože ma zaujíma vzťah voči dňom v týždni vynechal som pár posledných dní aby ich bol rovnaký počet. Jedná sa o 893 dní.

Príprava a ukážka dát

```
import pandas as pd
import matplotlib.pyplot as plt
import matplotlib.ticker as ticker
from scipy.stats import ttest_1samp
```

```
df = pd.read_csv('archive/russia_losses_equipment.csv')
df['date'] = pd.to_datetime(df['date'])
df.set_index('date', inplace=True)
print(df)
```

	day	aircraft	helicopter	tank	APC	field artillery	MRL	\
date								
2024-08-01	890	363	326	8399	16203	16119	1132	
2024-07-31	889	363	326	8390	16161	16086	1131	
2024-07-30	888	363	326	8381	16141	16056	1130	
2024-07-29	887	363	326	8356	16103	16010	1129	
2024-07-28	886	363	326	8344	16095	15936	1127	
...	...	...	...	...	...	...	...	
2022-03-01	6	29	29	198	846	77	24	
2022-02-28	5	29	29	150	816	74	21	
2022-02-27	4	27	26	150	706	50	4	
2022-02-26	3	27	26	146	706	49	4	
2022-02-25	2	10	7	80	516	49	4	

	military auto	fuel tank	drone	naval ship	\
date					
2024-08-01	NaN	NaN	12968	28	
2024-07-31	NaN	NaN	12853	28	
2024-07-30	NaN	NaN	12832	28	
2024-07-29	NaN	NaN	12805	28	
2024-07-28	NaN	NaN	12766	28	
...	...	...	...	...	
2022-03-01	305.0	60.0	3	2	
2022-02-28	291.0	60.0	3	2	
2022-02-27	130.0	60.0	2	2	
...					
2022-02-26	NaN	NaN			
2022-02-25	NaN	NaN			

Miesta, na ktorých je záznam NaN som nastavil na 0. Následne si vizualizujem graf denných strát techniky a vyznačím si niektoré zaujímavé udalosti. Je vidno že veľa týchto udalostí nasledoval nárast strát ruskej techniky.

```
# Znazornim si denne straty techniky(aircraft, helicopter, tank, APC, drone, Vehicles and fuel tanks, submarines, naval ship, MRL, military auto, aircraft warfare, mobile SBRM system)
# nasledne denne straty streliva a paliva (field artillery, cruise missiles, )

def sum_row_technic(row):
    return float(row['aircraft'] + row['helicopter'] + row['tank'] + row['APC'] + row['MRL'] + row['military auto'] + row['fuel tank'] + row['drone'] + row['naval ship']
               + row['anti-aircraft warfare'] + row['mobile SBRM system'] + row['vehicles and fuel tanks'] + row['submarines'])

df['technic_total'] = df.apply(sum_row_technic, axis=1)

df['daily_only_technic_losses'] = (df['technic_total'].diff().shift(-1).fillna(0)).abs() # Shift the losses up by one day
df.at[df.index[-1], 'daily_only_technic_losses'] = df.at[df.index[-1], 'technic_total']
print(df['daily_only_technic_losses'])

dates_to_highlight = ['2022-04-05', '2022-04-09', '2022-08-29', '2022-12-21', '2022-02-24', '2022-07-03', '2023-03-06', '2023-05-12',
                    '2023-09-25', '2024-02-01']


dates_to_highlight = [pd.to_datetime(date) for date in dates_to_highlight]

# Plot the daily technic losses
plt.figure(figsize=(16, 12))
plt.plot(df.index, df['daily_only_technic_losses'])

# Highlight specific dates with annotations
for date in dates_to_highlight:
    plt.axvline(x=pd.to_datetime(date), color='r', linestyle=':') # Vertical dashed red line

lines, labels = [], []
for date in dates_to_highlight:
    label_date_str = date.strftime("%Y-%m-%d")
    lines.append(plt.Line2D([0], [0], color='r', linestyle=':'))
    labels.append(f'Day {label_date_str}')
plt.legend(lines, labels, loc='upper right', title="Highlighted Days")

plt.title('Daily Only Technic Losses Over Time')
plt.xlabel('Date')
plt.ylabel('Number of Only Technic Lost Daily')
plt.xticks(rotation=20)
plt.tight_layout()
plt.show()
```



Z grafu je vidno, že najvyššie straty boli na začiatku invázie, v nasledujúcich mesiacoch klesali a celkom výrazne kolísali. Od cca apríla 2023 začali straty znova stúpať. Kolisavosť je podľa môjho názoru zapríčinená pripravovaním väčších útokov a taktiež obliehaním miest. Vplyv mali tiež momenty kedy sa začala využívať darovaná technika Ukrajinskej armáde.

Udalosti vyznačené v grafe

2022-02-24 - Obliehanie Mariupolu

2022-04-05 - Dodanie prvých tankov od ČR. <https://www.reuters.com/world/europe/czech-republic-sends-tanks-ukraine-czech-tv-reports-2022-04-05/>

2022-04-09 - Dodanie protivdušných systémov obrany od SR. <https://www.mosr.sk/51353-en/s-300-nahradi-jeden-z-najmodernejších-systémov-protivzdušnej-obrany/>

2022-07-03- Obliehanie Bakhmutu

2022-08-29 - Zahájenie ukrajinskej protiofenzívy. <https://www.politico.eu/article/ukraine-liberates-kherson-army-war-defeat-russia-dnipro/>

2022-12-21 - USA poskytla Ukrajine protivdušný systém obrany Patriot. <https://www.reuters.com/world/europe/what-is-patriot-missile-defense-system-2022-12-21/>


2023-03-06 - Najnáročnejšie boje v Bakhmute.(7. marca sa ukrajinská armáda stiahla z Bakhmutu).

2023-05-12 - Doručenie stromshadow air-lunched cruise-missile od UK


2023-09-25 - Ukrajine boli dodané prvé tanky M1 Abrams. <https://www.nytimes.com/2023/09/25/world/europe/us-abrams-tanks-ukraine.html>

2024-02-01 - EU sa odhodla na darovanie 54 miliárd dolárov pre Ukrajinu. https://www.eeas.europa.eu/delegations/united-states-america/eu-assistance-ukraine-us-dollars_en?s=253

V prípade denných strát munície a riadených striel vyzerá graf obdobne:




Graf celkových strát techniky spolu s muníciou:





Analýza

Moja nulová hypotéza, ktorú budem skúmať H_0 : Veľkosť strát techniky nieje závislá od dňa v týždni. Čo v našom prípade znamená, že strata techniky z konkrétného dňa sa nebude výrazne líšiť od očakávanej priemernej straty. Z grafu priemerných strát v dni týždňa je však vidieť že najviac sa v priemere stratí v piatok a vo štvrtok.



Znázornenie distribúcie strát techniky na základe dňa v týždni koláčovým grafom:




Načrtnem si ešte histogram denných strát, kde vidím že najčastejšie vyskytujúce sa hodnoty sú niekde okolo 70

```
plt.figure(figsize=(15, 12))
plt.hist(df['daily_only_technic_losses'], bins=130, edgecolor='black')
plt.title('Distribution of Daily Technic Losses')
plt.xlabel(['Amount of Loss'])
plt.ylabel('Number of Days')
plt.show()
# pripomina nejake deformovane normalne rozdelenie
# data su relativne normalne rozdelenne
```

✓ 0.1s

Distribution of Daily Technic Losses



Ako posledné si zobrazím ešte distribúciu strát techniky pre jednotlivé dni týždňa

```
# Create a subplot for each day of the week with a 2x4 grid
fig, axs = plt.subplots(nrows=2, ncols=4, figsize=(20, 10))
axs = axs.ravel() # Flatten the array

# limits for axis
x_min, x_max = 0, 1000
y_min, y_max = 0, 500


#print(max(df['daily_only_technic_losses']) + 1)

for i, day in enumerate(days_of_week):
    day_losses = df[df['day_of_week'] == i]['daily_only_technic_losses']
    # Plot histogram for the day
    axs[i].hist(day_losses, bins=20, edgecolor='black', color='skyblue') # Adjust bins as needed
    axs[i].set_title(f'{day} Losses')
    axs[i].set_xlabel('Amount of Loss')
    axs[i].set_ylabel('Frequency')

# removing empty frame
if len(days_of_week) < len(axs):
    axs[-1].remove() # This removes the last subplot if it's not used
plt.tight_layout()
plt.show()

# data su relativne normalne rozdelené
```

✓ 0.6s



Z histogramov vidno že v piatok, kde priemerné straty boli najvyššie sa často vyskytujú hodnoty medzi 0 a 150 raz sa ale stalo že v piatok boli straty skoro 800, preto priemer vyšiel vyšší. Preto si myslím že hypotéza H_0 by sa mohla potvrdiť. Pre náš prípad nieje predpoklad aproximácie veľkosti strát normálnym rozdelením potrebný.

Pri testovaní chceme vlastne zistiť či sa straty z konkrétnych dní výrazne líšia od priemernej straty. tj. čísla

$$\mu_d = \frac{\sum_{s \in d} \text{veľkosť strát v deň } s}{|d|},$$

kde d sú všetky dni z ktorých máme záznam o stratách. Túto odlišnosť a jej signifikanciu určíť pomocou jednovýberového t-testu. Použijem na to funkciu `ttest_1samp` z knižnice `scipy.stats` a ako parametre jej predám denné straty techniky a priemernú dennú stratu techniky. Za hladinu významnosti si zvolím typicky $\alpha = 0.05$.

```
# T-test
# spocita mi_r a urci t-hodnoty a p-hodnoty
# one sample t-test
# two-tailed alternative='two-sided' is the default value, checking for a two-sided alternative hypothesis
average_daily_loss = df['daily_only_technic_losses'].mean()
print(average_daily_loss)

for day in days_of_week:
    day_losses = df[df['day_of_week'] == days_of_week.index(day)]['daily_only_technic_losses']
    # Perform one-sample t-test against the overall mean loss
    t_statistic, p_value = ttest_1samp(day_losses, average_daily_loss)
    print(f"{day}: T-statistic = {t_statistic}, P-value = {p_value}")
```

69.90213723284589

Monday: T-statistic = -0.9795458315490803, P-value = 0.3291874017438906
Tuesday: T-statistic = -0.46440215832118237, P-value = 0.6431610759445054
Wednesday: T-statistic = -0.04969671531621782, P-value = 0.9604427670342814
Thursday: T-statistic = 1.06016390717508, P-value = 0.2910980459223831
Friday: T-statistic = 0.8075698689149147, P-value = 0.4208601655627199
Saturday: T-statistic = -0.4087804514031083, P-value = 0.6833947309862864
Sunday: T-statistic = -0.45816042840044785, P-value = 0.647626376379667

Ako vidieť z výsledkov, p-hodnoty pre všetky dni sú rádovo vyššie ako 0.05 a preto túto hypotézu nemôžeme zamietnuť.

Záver, Diskusia

Pri overovaní hypotézy o závislosti dňa v týždni sme dospeli k záveru že môžeme tvrdiť: veľkosť strát techniky nie je štatisticky významne závislá od dňa v týždni. A pretože sú p-hodnoty pre všetky dni výrazne nad hladinou významnosti 0.05 podporuje to našu hypotézu H_0 . Závislosti voči dňom sú relatívne slabé a bolo by zaujímavé skúmať tieto straty voči hodiny dňa, kde by sa mohli ukázať zaujímavé pozorovania, taktiež by sa dala spraviť aj analýza lokácií v ktorých sú tieto straty najvyššie.